

Predicción de atrasos

en rutas de última milla

De reaccionar a los atrasos a anticiparlos con datos

Modelo de alerta operativa para detectar riesgo, estimar severidad y focalizar acciones antes de que el atraso ocurra.



Anticipar atrasos antes de que impacten al cliente

El desafío no es solo medir que entregas llegaron tarde, sino detectar riesgo mientras todavía hay margen operativo para actuar.

Problema operativo

1 de cada 10

entregas llega tarde

Ese grupo minoritario concentra costo: espera del cliente, reprogramaciones, llamadas y pérdida de confianza.

Objetivo del proyecto

CLASIFICACIÓN

¿Llegará tarde?

Detectar riesgo de atraso
Sí / No

REGRESIÓN

¿Cuántos minutos?

Estimar severidad
del delay

Resultado esperado: pasar de reaccionar tarde a priorizar entregas en riesgo antes de que el atraso ocurra.

CRISP-DM aplicado al problema

La presentación sigue la misma lógica del proyecto: entender el negocio, preparar datos, modelar y traducir resultados a decisiones.

1

Business Understanding

Problema operativo y objetivos

2

Data Understanding

Variables, atraso, calidad y outliers

3

Data Preparation

Limpieza, features y split temporal

4

Modeling

Clasificación, regresión y clustering

5

Evaluation

Métricas, umbrales y validación temporal

6

Recommendations

Alertas y acciones focalizadas

Variables del dataset: qué sabemos de cada entrega

El dataset combina planificación, ejecución y contexto. Desde ahí se construyen dos objetivos: atraso sí/no y minutos de delay.

PLANIFICACIÓN

Earliest Time
Latest Time
IndexP
DistanceP

EJECUCIÓN

Arrived Time
IndexA
DistanceA
route_deviation

CONTEXTO OPERATIVO

Week ID
Country
Day of Week
Route ID
Driver ID

Variable objetivo categórica

delayed -> llega tarde / no llega tarde


Variable objetivo numérica

delay -> minutos de atraso respecto al límite

Lectura inicial: el atraso afecta a ~9-10% de entregas; no es masivo, pero concentra costo y riesgo operacional.

La correlación lineal no alcanza para explicar el atraso

El heatmap se usa como diagnóstico: muestra redundancias y riesgos de leakage, pero también evidencia que hace falta feature engineering.



Tres lecturas clave



No hay una correlación única dominante con delayed
La clase atrasada no se explica por una sola variable original.



Hay redundancias y relaciones mecánicas
IndexP/IndexA, DistanceP/DistanceA y Latest Time vs delay deben leerse con cuidado.



La señal aparece al construir contexto
Por eso se crean ventana, historial del conductor y acumulación de atrasos en ruta.

IDs, Depot y Day of Week se analizaron fuera de esta matriz principal.

Preparar datos sin borrar realidad operacional

La limpieza elimina inconsistencias claras, pero conserva extremos plausibles que representan rutas reales.

1

Limpiar invalidos

Tiempos imposibles, ventanas invalidas y registros fuera de escala.

2

Conservar outliers plausibles

Distancias largas, muchas paradas o desviaciones pueden ser operación real.

3

Validar y transformar

0 nulos en X, Day of Week con OHE y escalado solo desde train.

4

Separar temporalmente

Entrenar con semanas anteriores y evaluar semanas posteriores.

Salida para modelado

Dos versiones de X: escalada para modelos lineales y sin escalar para árboles. En ambos casos, el scaler se ajusta solo con train.

Las variables derivadas revelan señales que no estaban claras

Después de la matriz original, se construyen variables que capturan margen horario, acumulación de atrasos e historial operativo.

Ventana

margen horario

Plan vs ejecución

diferencias plan/real

Ruta en curso

atraso acumulado

Historial conductor

comportamiento previo

La mejora viene del contexto acumulado, no solo de variables crudas.



Heatmap
derivadas + targets

Lectura

Las señales de ruta e historial conectan mejor con delayed.

Conjuntos de variables usados en las iteraciones

Cada set prueba una hipótesis distinta sobre que información aporta valor predictivo.



Cómo leer los resultados de los modelos

Las métricas conectan desempeño técnico con decisiones: alertar mejor y estimar minutos con menor error.

Clasificación: riesgo de atraso

F1

Balance entre precision y recall
Métrica principal para comparar clasificadores.

Recall

Cuantos atrasos reales detecta
Clave si perder un atraso cuesta más que una falsa alarma.

Precision

Calidad de las alertas emitidas
Evita saturar a operaciones con alertas falsas.

AUC

Ordena casos por riesgo
Indica si el modelo rankea bien antes de fijar umbral.

Regresión: minutos de delay

RMSE

Error en minutos penalizando grandes fallos
Principal cuando errores grandes son costosos.

MAE

Error absoluto promedio
Lectura directa: minutos promedio de error.

R2

Varianza del delay explicada
Mide capacidad global de explicar el comportamiento.

Late

Predicción media en atrasadas
Valida si reconoce la dirección del atraso real.

Accuracy se reporta, pero no decide: con clases desbalanceadas puede verse alta aunque el modelo ignore los atrasos.

Regresión Logística

Benchmark interpretable

Modelo base para medir cuánto aportan las nuevas señales antes de pasar a modelos no lineales.

Cómo funciona

- Calcula probabilidad de atraso.
- Es simple y explicable.
- No captura bien relaciones complejas.

Qué se probó

- 10 iteraciones de variables.
- Sin outliers: casi sin cambio.
- El salto vino con señales secuenciales e históricas.

F1 atrasada

0.5180

AUC-ROC

0.9068

Accuracy

0.8722

BASE

OK

Análisis ejecutivo

Competitiva con F_FULL

Las variables enriquecidas levantan claramente el baseline.

La ventana horaria pesa

Quitar información temporal degrada fuerte el rendimiento.

Sirve como vara

Exige que los modelos no lineales superen F1=0.518.

Conclusión: buen baseline; el potencial real requiere modelos no lineales.

Árbol de Decisión: reglas claras, pero alta varianza

Permite leer decisiones tipo "si pasa esto, entonces riesgo", aunque un árbol único sobreajusta rápido.

Cómo funciona

- Divide los datos en reglas sucesivas hasta separar casos.
- Muy interpretable, pero memoriza si no se poda.
- Necesita controlar profundidad y tamaño de hoja.

Qué se probó

- Sin límite: profundidad 40, F1 train=1.0 y mal test.
- max_depth=10 fue el mejor equilibrio.
- min_samples_leaf=50 redujo overfitting y mejoró AUC.

F1 atrasada

0.4650

AUC-ROC

0.8893

Accuracy

-

LECTURA

No supera LR

Análisis ejecutivo

- Confirma que las señales secuenciales/históricas explican el salto.
- Aún regularizado queda por debajo de LR con F_FULL.
- La conclusión técnica: un árbol solo no alcanza; hace falta un ensemble.

Random Forest: mejor clasificador del proyecto

Combina muchos árboles independientes para reducir varianza y estabilizar la predicción.

Cómo funciona

- Entrena multiples árboles sobre muestras y variables distintas.
- Promedia/vota, evitando depender de una sola estructura.
- Funciona muy bien cuando hay relaciones no lineales y ruido.

Qué se probó

- F_RED_FULL y F_TOP para reducir ruido.
- Barrido de max_features confirmó sqrt.
- min_samples_leaf=5 fue el ajuste clave.

F1 atrasada

0.5917

AUC-ROC

0.9221

Accuracy

0.9128

LECTURA

Modelo lider

Análisis ejecutivo

- Supera a todos los modelos de clasificación en F1.
- F_TOP=13 mejora al quitar Week ID y día de semana como ruido.
- Con umbral operativo 0.41 detecta cerca de 75 de cada 100 atrasos reales.

Gradient Boosting: separa bien, pero con perfil rígido

Construye árboles secuenciales: cada nuevo árbol corrige errores del anterior.

Cómo funciona

- Aprende de forma incremental corrigiendo residuos.
- Suele lograr alta capacidad de separación.
- El tradeoff precision/recall puede quedar rígido si el umbral no acompaña.

Qué se probó

- Se probaron learning rate, n_estimators, max_depth y subsample.
- max_depth fue la única palanca realmente efectiva.
- El mejor punto fue depth=6 con F_TOP=13.

F1 atrasada

0.5211

AUC-ROC

0.9226

Accuracy

-

LECTURA

AUC alto

Análisis ejecutivo

- Tiene AUC comparable a RF, pero F1 bastante menor.
- Mantiene recall alto y precision baja en casi todas las variantes.
- Necesitaria optimización de umbral para traducir mejor su separación en decisiones.

HistGradientBoosting: boosting más eficiente y flexible

Usa histogramas para acelerar particiones y permite mayor expresividad que GB clásico.

Cómo funciona

- Agrupa valores numéricos en bins para entrenar más rápido.
- Controla complejidad con max_leaf_nodes y min_samples_leaf.
- Captura no linealidad con buen costo computacional.

Qué se probó

- F_TOP=13 como set base.
- max_leaf_nodes fue el lever que movió el perfil.
- min_samples_leaf casi no cambio el resultado.

F1 atrasada

0.5446

AUC-ROC

0.9228

Accuracy

-

LECTURA

Segundo mejor

Análisis ejecutivo

- Supera a LR y GB, confirmando mayor expresividad.
- Aún así no alcanza a RF: la brecha en F1 queda cerca de 0.047.
- Buena alternativa si se prioriza velocidad y AUC, no el máximo F1.

XGBoost: mejor ranking probabilístico, no mejor F1

Boosting regularizado, potente y robusto; excelente para ordenar riesgo, menos ganador en umbral 0.50.

Cómo funciona

- Construye árboles secuenciales con regularización L1/L2.
- Maneja desbalance con scale_pos_weight.
- Suele destacar por estabilidad y ranking de probabilidades.

Qué se probó

- 5 iteraciones: depth, n_estimators, subsample/colsample y learning rate.
- depth=6, n=200, lr=0.1 maximizó AUC.
- Más complejidad no rompió el techo de F1.

F1 atrasada

0.5293

AUC-ROC

0.9236

Accuracy

-

LECTURA

Mejor AUC

Análisis ejecutivo

- Tiene el AUC más alto de clasificación, señal de excelente ranking.
- Pero su F1 queda bajo RF e HGB con el umbral por defecto.
- Conclusión: muy buen candidato si el negocio calibra umbrales, no como ganador directo de F1.

Random Forest queda como modelo recomendado para alertas

La selección no depende solo del AUC: para el negocio importa detectar atrasos reales con un balance razonable de falsas alarmas.

Ranking de modelos finales

Modelo	F1 atrasada	AUC-ROC	Lectura
Random Forest	0.5917	0.9221	Mejor F1 y modelo elegido
HGB	0.5446	0.9228	Segundo mejor; muy buen AUC
XGBoost	0.5293	0.9236	Mejor ranking probabilístico
Gradient Boosting	0.5211	0.9226	AUC alto, F1 rígido
Regresión Logística	0.5180	0.9068	Baseline fuerte
Decision Tree	0.4650	0.8893	Interpretable, pero limitado

Decisión metodológica

Se elige Random Forest porque maximiza F1 en la clase atrasada: es el mejor equilibrio entre detectar atrasos y controlar falsas alarmas.

Matiz importante

XGBoost y HGB rankean muy bien el riesgo (AUC alto), pero con el umbral por defecto no convierten esa separación en mejor F1.

Lectura de negocio

El modelo no reemplaza la operación: prioriza la atención. Sirve para enfocar supervisores, conductores y replanificación donde el riesgo es mayor.

Mensaje clave: no buscamos el modelo más complejo, sino el que mejor convierte datos históricos en alertas accionables para reducir atrasos.

Segundo objetivo: estimar minutos de atraso

Después de detectar si una entrega está en riesgo, el negocio necesita dimensionar la severidad: no es lo mismo llegar 5 minutos tarde que 90.

1

Clasificador detecta riesgo

2

Regresor estima magnitud

3

Operación prioriza
acciones

Métricas centrales: RMSE/MAE para error en minutos, R2 para explicación global y `pred_late` para validar señal en entregas atrasadas.

Familia lineal: baseline y selección de variables

OLS, Ridge y Lasso fijan el piso: explican parte del delay, pero no capturan bien los atrasos reales.

Cómo funciona

- Predicen delay como suma ponderada de variables.
- Ridge estabiliza coeficientes; Lasso elimina variables redundantes.
- Son utiles para interpretar, no necesariamente para producir.

Qué se probó

- OLS con F_BASE y F_FULL.
- Ridge para regularización L2.
- Lasso alpha=1 seleccionó 15 features y fue el mejor lineal.

RMSE

80.29

MAE

~60

R2

0.726

Pred late

neg.

Mejor lineal: Lasso, pero no sirve como modelo final

Análisis ejecutivo

- El techo lineal queda cerca de R2=0.72-0.73.
- Lasso confirma variables relevantes: Latest Time, ventana, IndexA e historial.
- Problema de negocio: en entregas atrasadas mantiene predicción media negativa.

Decision Tree Regressor: no linealidad con reglas simples

Primer modelo no lineal: mejora al lineal, pero sigue limitado como árbol único.

Cómo funciona

- Divide el espacio en reglas y predice el promedio de cada hoja.
- No necesita escalamiento y tolera colinealidad.
- Sin poda memoriza el entrenamiento.

Qué se probó

- Sin límite: RMSE 95.26, overfitting extremo.
- Barrido de profundidad entre 3 y 20.
- max_depth=10 fue el mejor punto.

RMSE

78.16

MAE

57.16

R2

0.740

Pred late

-12.39

Mejora al lineal, pero falla en la cola

Análisis ejecutivo

- Captura algo de no linealidad y mejora RMSE.
- Aún predice signo negativo en atrasos reales.
- Sirve para justificar ensembles: un árbol solo no estabiliza suficiente.

Random Forest Regressor: mejor error global

Promedia muchos árboles para reducir varianza y lograr el menor error general del test.

Cómo funciona

- Entrena muchos árboles independientes con bootstrap.
- Promedia predicciones para estabilizar el error.
- Muy fuerte en datos tabulares con patrones claros.

Qué se probó

- Baseline con 100 árboles.
- Barrido de min_samples_leaf.
- max_features=0.7 mejoró RMSE y mantuvo señal en cola.

RMSE

65.16

MAE

46.07

R2

0.819

Pred late

+5.06

Mejor RMSE global

Análisis ejecutivo

- Es el modelo con menor error promedio global.
- La señal en atrasados es positiva, pero moderada.
- Buen candidato si se prioriza precision global y simplicidad operativa.

Gradient Boosting Regressor: buen ajuste, cola débil

Aprende secuencialmente corrigiendo errores, pero en este dataset subestima los atrasos.

Cómo funciona

- Cada árbol corrige el error residual del anterior.
- Generaliza de forma controlada con learning rate bajo.
- Puede quedar corto si la señal de cola requiere más capacidad.

Qué se probó

- Baseline depth=3.
- Barrido de profundidad.
- Final con depth=6, lr=0.05, n=200.

RMSE

67.22

MAE

48.82

R2

0.808

Pred late

+1.61

Generaliza, pero casi no ve la cola

Análisis ejecutivo

- Rinde bien globalmente, pero queda bajo RF/HGB/XGB.
- Pred_late apenas positivo: alerta de subestimación.
- No es el modelo recomendado para dimensionar atrasos.

HistGradientBoosting: mejor señal de negocio en atrasos

Boosting eficiente con histogramas; sacrifica poco error global y gana mucha señal en la cola.

Cómo funciona

- Usa bins de histogramas para acelerar los splits.
- Early stopping no corto: el modelo seguía aprendiendo.
- La regularización efectiva vino por max_depth.

Qué se probó

- P1 max_iter=500.
- P2 max_iter=1500 mejoró cola pero subió gap.
- depth=5 fue equilibrio entre gap y pred_late.

RMSE

66.31

MAE

47.84

R2

0.813

Pred late

+9.46

Mejor lectura de atrasos reales

Análisis ejecutivo

- Empata a RF/XGB en error global prácticamente.
- Tiene la mayor predicción media en entregas atrasadas.
- Si el foco es severidad del atraso, es el modelo más útil para negocio.

XGBoost Regressor: mejor balance error/gap/cola

Boosting regularizado con muestreo de filas y columnas; muy competitivo y estable.

Cómo funciona

- Construye árboles secuenciales con regularización explícita.
- subsample y colsample controlan sobreajuste.
- Excelente cuando se busca balance entre error y estabilidad.

Qué se probó

- P1 con 200 árboles quedó corto.
- Barrido de `n_estimators` mostró convergencia cerca de 1000.
- `subsample=0.7` y `colsample=0.7` fue el mejor balance.

RMSE

66.15

MAE

47.93

R2

0.814

Pred late

+8.37

Balance más robusto entre boosters

Análisis ejecutivo

- RMSE casi igual al mejor global y gap más contenido que HGB.
- Pred_late fuerte, aunque menor que HGB.
- Muy buen candidato si se privilegia estabilidad temporal y control de sobreajuste.

RF gana en error global; HGB/XGB ganan en severidad

La regresión no tiene un único ganador absoluto: depende de si el negocio prioriza error promedio o capacidad de cuantificar atrasos reales.

Ranking de modelos finales

Modelo	RMSE	R2	Pred late	Lectura
RF Final	65.16	0.819	+5.06	Menor error global
XGB Final	66.15	0.814	+8.37	Mejor balance
HGB Final	66.31	0.813	+9.46	Mejor cola
GB Final	67.22	0.808	+1.61	Cola débil
DT Final	78.16	0.740	-12.39	No recomendable
Lasso	80.29	0.726	neg.	Baseline lineal

Si se prioriza error promedio

Elegir RF: menor RMSE y MAE global, con configuración relativamente simple.

Si se prioriza severidad

Elegir HGB: mejor pred_late, cuantifica mejor los atrasos reales.


Si se prioriza estabilidad

Elegir XGB: pred_late fuerte con gap más controlado que HGB.

Recomendación: usar RF como referencia global y HGB/XGB como modelos de severidad para priorizar casos atrasados.

Los modelos se validan respetando el tiempo

TimeSeriesSplit responde si el resultado es estable en distintas ventanas temporales, sin entrenar con información futura.



Por qué no KFold clásico

KFold mezcla semanas al azar. En este problema eso permitiría entrenar con semanas futuras para predecir semanas pasadas: fuga temporal.

Clasificación confirmada

Random Forest gana en los 5 folds. F1 medio = 0.603 +/- 0.021 frente a XGB = 0.548 +/- 0.028.

Regresión matizada

RF y XGB empatan: RMSE medio ~70 min y R2 ~0.80. XGB queda apenas más estable.

Conclusión: la selección de RF en clasificación es robusta; en regresión la elección puede depender de simplicidad, severidad o estabilidad.

Segmentación operativa: entender perfiles de entrega

KMeans y GMM no predicen directamente; agrupan entregas similares para descubrir segmentos de riesgo accionables.

KMeans

Encuentra grupos naturales con asignación dura. Con $k=3$ separa: Express (1%, 0% atrasos), Estándar (60%, 8.1%) y Riesgo latente (39%, 11.4%).

GMM

Usa gaussianas elípticas y asignación blanda. Aísla un cluster de alto riesgo: 14% de entregas con 32.2% de atraso.

Soft clustering

La confianza media de asignación fue 0.994. Solo 0.3% queda ambiguo: los perfiles son nítidos, no una partición arbitraria.

Hallazgo principal

El atraso no aparece como un grupo aislado por promedio de delay; aparece como un perfil de mayor riesgo dentro de la operación.

GMM lo vuelve accionable: 14% de entregas concentra una tasa de atraso de 32.2%.

Uso de negocio: priorizar auditoría, refuerzo de ruta y monitoreo sobre segmentos con riesgo estructuralmente mayor.

Qué modelo responde cada pregunta de negocio

El proyecto no termina en un único algoritmo: combina detección, estimación y segmentación para apoyar decisiones operativas.

1. Detectar riesgo

Pregunta: Llegará tarde?

Modelo recomendado: Random Forest clasificación.

Por qué: mejor F1, robusto en validación temporal y buen punto de operación con umbral 0.41.

2. Estimar severidad

Pregunta: cuántos minutos?

Modelo recomendado: RF para error global; HGB/XGB para severidad.

Por qué: RF minimiza RMSE, HGB/XGB leen mejor la cola de atrasados.

3. Segmentar operación

Pregunta: dónde focalizar?

Modelo recomendado: GMM como apoyo analítico.

Por qué: aísla 14% de entregas con tasa de atraso 32.2%.

Sistema propuesto de uso operativo

Clasificador prioriza alertas -> Regresor estima impacto -> Segmentación define donde intervenir primero

Qué aprendimos sobre los atrasos

El atraso no se comporta como un evento aislado: aparece como resultado acumulado de ruta, historial y contexto operativo.

Entregas tarde

9-10%

Atrasos detectables

75/100

Segmento crítico

14%

Tasa en segmento

32.2%

1. El riesgo se acumula

Las señales secuenciales e históricas explican gran parte del salto de rendimiento. Si una ruta ya viene atrasada, las siguientes paradas heredan riesgo.

2. No todo extremo es error

Algunos outliers son operación real. La limpieza se enfocó en inconsistencias, no en borrar casos difíciles que el negocio necesita anticipar.

3. El riesgo está concentrado

GMM identificó un segmento pequeño pero crítico: cerca del 14% de entregas con una tasa de atraso de 32.2%.

Insight central: la oportunidad no está en tratar toda la operación igual, sino en intervenir donde el riesgo se concentra.

Cómo usar el modelo en la operación

El objetivo no es reemplazar al equipo operativo, sino darle señales tempranas para actuar antes de que el atraso se consolide.

Alerta temprana en ruta

Activar alertas cuando el clasificador marca alto riesgo, especialmente después de una parada atrasada. Permite re-secuenciar, contactar cliente o reforzar antes de que se propague.

Gestión del conductor

Usar historial de atraso como señal de seguimiento: capacitación, apoyo en rutas complejas o reasignación preventiva cuando hay patrones recurrentes.

Balanceo de carga

Evitar dejar entregas críticas al final de rutas con alto riesgo acumulado. Priorizar clientes sensibles y redistribuir carga en segmentos críticos.

Siguientes mejoras

Agregar variables externas (tráfico, clima, hora real, densidad/zona, tipo o prioridad de entrega) y recalibrar periódicamente con nuevas semanas de datos.

De reaccionar a los atrasos a anticiparlos

El valor del proyecto está en la cadena completa: detectar riesgo, estimar severidad, segmentar la operación y actuar de forma focalizada.

1 Detectar

RF identifica entregas con riesgo de atraso.

2 Dimensionar

Regresión estima impacto en minutos.

3 Focalizar

GMM encuentra segmentos de mayor riesgo.

4 Actuar

Operación prioriza recursos y decisiones.

La ventaja no es predecir por predecir: es intervenir antes, en menos casos, con mayor impacto.